

作业与资源管理用户手册

2020 年 12 月 01 日

1	基本概念与环境说明.....	1
1.1	基本概念.....	1
1.1.1	作业与作业 ID	1
1.1.2	任务与任务分布.....	1
1.1.3	作业队列.....	1
1.1.4	作业类型.....	2
1.1.5	作业运行模式.....	2
1.1.6	作业生命周期.....	3
1.1.7	作业输出.....	3
1.2	使用环境说明.....	3
2	系统使用指南.....	4
2.1	用户管理.....	4
2.2	资源管理.....	4
2.2.1	节点查询命令.....	4
2.2.2	队列查询命令.....	6
2.2.3	队列状态查询.....	6
2.3	开工管理.....	7
2.3.1	指定 CPU 开工.....	7
2.3.2	队列开工.....	8
2.4	作业管理.....	8
2.4.1	作业提交.....	8
2.4.2	作业查询.....	11
2.4.3	作业输出查询.....	12
2.4.4	作业联机.....	12
2.4.5	作业废除.....	13

1 基本概念与环境说明

1.1 基本概念

1.1.1 作业与作业 ID

作业：是上机用户编写的经过编译后的并在主机上运行的用户可执行程序或脚本。用户作业程序的编写可以使用并行 C、MPI、OpenMP 等各种编程语言和环境，最终以可执行程序的形式存在，并以作业的形式被提交到主机中运行。

任何作业都必须提交到某个指定的队列中调度运行。

作业 ID：每道作业有唯一的**作业 ID**（整数，JOBID），这也是作业的唯一性标识。

作业管理：普通用户运行课题时，以标准批作业管理命令接口的形式向用户开放作业服务环境，通过它们可以提交作业，并对作业进行各种管理和控制。作业的调度和运行时控制由作业管理系统自动完成。

计算节点：这里的计算节点，就是指一个操作系统核心。

计算节点号 (nodeid)：是计算节点的编号，就是每个操作系统核心所在 CPU 的编号。

1.1.2 任务与任务分布

- 1) **主核任务：**是一个作业的基本组成单元，是在一个指定计算节点上执行的一个 POSIX 会话，通常是一个进程。对于并行课题来说，就是用户作业运行过程中的进程。
- 2) **任务分布模式：**作业管理支持多种任务分布模式。对于 MPI、并行 C 以及批量单任务作业来说，主核上使用的作业所有任务（进程）都是由作业管理启动的，在对任务编号时，作业管理将对一个 OS 内的作业任务进程按照创建顺序进行编号。而对于每节点使用的 CG 及从核，包括以下几种模式：
 - a) **指定每个 CG 使用从核个数。**是作业管理缺省控制模式，每个 CG 启动相同个数的从核任务。
 - b) **不使用从核模式。**作业只使用主核，不使用从核。
 - c) **指定每主核使用 CG 数，默认为 1，可选参数为 1-6**

1.1.3 作业队列

(1) **作业队列：**是计算机面向用户的上机门户，用户的所有课题以作业的形式提交运行，都是提交到某个队列中的。队列由管理员创建和管理、由普通用户使用。用户可以像使用标准 LSF 等作业管理环境一样使用队列系统。

面向用户和高层开发环境界面，系统以标准**作业队列**的形式开放作业服务环

境。

(2) **作业流程**: 所有用户运行课题以作业的形式提交到指定的队列中, 系统为每道作业分配唯一的作业 ID, 作业在队列中排队, 接受作业管理系统的自动调度运行。运行时, 根据作业服务环境的队列属性允许普通用户对作业进行人机交互控制, 或者由系统自动批处理。

1.1.4 作业类型

在系统中, 系统支持三种类型的作业:

- a) **串行作业**: 采用串行 C、Fortran 等语言编写的单进程串行应用程序或者 shell 程序, 这种作业是指在作业提交时刻指定只需要启动一个任务, 而且提交时作业的语言类型参数为空, 系统就作为串行作业运行。
- b) **并行作业**: 采用并行 C、MPI、OpenACC 等编程环境编写的多任务并行应用程序。
- c) **批量单任务作业**: 用户有时候需要将 1 个串行程序同时提交到多个节点上运行, 各个进程之间协同完成某个工作, 而且要求这些进程作为一道作业。这就是批量单任务作业。它实际上可以是一个串行进程的多个相同的副本组成的同时执行的一组进程的集合。

1.1.5 作业运行模式

系统作业服务提供两种作业运行模式: **交互作业**、**批式作业**。作业运行模式的选择由用户决定。

- a) **交互作业**: 用户在作业提交命令 `bsub` 命令中指定 `-I` 参数选择交互作业服务模式。作业提交后, 作业运行信息在终端窗口中实时输出, 允许用户进行各种人机交互控制。这种运行模式适合于进行课题调试时使用。一旦提交窗口被意外关闭, 作业将自动转为脱机状态, 不会终止, 用户可以通过作业联机命令 (`bonline`) 重新在终端窗口接收作业的实时输出。交互运行模式下, 如果系统发现当前队列中的空闲资源不能满足该作业的资源需求, 作业提交时将自动报错退出。
- b) **批式作业**: 用户在作业提交命令 `bsub` 命令中不指定 `-I` 参数提交批式作业。批作业提交方式后, 系统根据机时和负载情况自动运行, 并将结果输出文件保存在全局文件系统中。这种作业的特点是作业提交运行后, 提交的窗口可以马上关闭, 作业不受任何影响。作业一旦开始运行, 作业的标准输出和错误输出都将被自动重定向, 如果提交时指定了输出定向的文件, 则将输出到对应的文件中, 否则系统将进行缓存。作业运行过程中, 可以通过相应的命令查询作业输出。批作业运行模式下, 即使当前队列中的空闲资源不能满足本作业的需求, 但只要队列中的总资源数满足本作业需求, 作业将排队等待。由于交互作业在实时终端窗口的输入或操作都会对作业产生影响, 所以相比之下批式作业更适合业务课题的

运行，建议所有业务运行的课题都使用批作业模式提交。

1.1.6 作业生命周期

作业生命周期的起点是用户成功地将作业提交到系统中，终点是作业的完成并退出。在作业生命周期中的任何时刻都有对应的作业状态。作业状态转换关系如图 1 所示。作业状态包括：排队、启动、运行、结束、退出。




图 1 作业状态转换关系图

作业状态含义：

- a) **PEND**：作业正在调度。正在队列中进行调度并等待分派，尚未选择和分配到系统资源，作业还没有开始执行，没有占用实际的资源。
- b) **STARTING**：作业正在启动运行。是作业已经分配资源后到作业正式启动完成开始运行之间的过渡状态。
- c) **RUN**：作业正在运行。作业已经完成调度并分派，作业占用的系统资源，正在运行中。
- d) **DONE**：作业正常完成并退出。
- e) **EXIT**：作业异常完成并退出。

1.1.7 作业输出

- a) 在系统作业管理系统中，用户作业具备标准输入、输出、错误输出能力。
- b) 作业的所有任务进程都可以使用标准输出和错误输出，系统建议用户在编写课题时尽可能减少课题的打印输出，否则严重影响课题运行的性能。
- c) 对于交互式作业，作业的标准输入/输出都在作业控制终端上完成。
- d) 对于批式作业，作业的标准输入由用户指定标准输入文件，标准输出由用户指定标准输出文件。

1.2 使用环境说明

系统为上机人员提供全局上机用户。例如 `swosenv`, `swtest` 等，这些用户都在

全局文件系统上。

系统面向用户应用服务节点，上机用户可登陆到应用服务节点上进行课题编辑、编译和提交运行等。目前提供的物理应用服务节点为 2 台，地址为 40.0.0.1-40.0.0.2，虚拟应用服务节点若干台，地址为 40.0.1.x

2 系统使用指南

2.1 用户管理

普通上机用户需由系统管理员创建，用户创建后，上机用户可以在登录后通过口令修改命令 `cpasswd` 自行对口令进行修改设置。

命令格式	
<code>cpasswd [username]</code>	
功能说明	
修改用户密码。	
注意事项	
1) 普通用户，执行 <code>cpasswd</code> ，根据提示输入口令即可。	

2.2 资源管理

用户通过资源查询命令可以查看当前本用户可用的队列名称、资源数量和资源状态。

2.2.1 节点查询命令

命令格式	
<code>cnload -h <-c cpulist -o struid -j jobid> [-l] [-w] [-b]</code>	
功能说明	
指定 CPU 列表查询节点状态	
参数说明	
<code>-h</code>	显示命令帮助
<code>-c</code>	显示一组指定 CPU 的状态信息

-o	显示指定结构号的 CPU 的状态信息
-j	显示指定作业占用的 CPU 的状态信息
-l	以长格式显示节点信息，包括作业号
-w	以表格参数显示节点统计信息
-b	显示指定目标的主从核的实时位图信息
格式说明	
1) 在指定 CPU 时，节点列表的格式：x-y, z, a-b，与 word 打印中选择页码范围的用法相同 2) 在指定结构号是，结构号格式：机舱号：中板号：插件板号：板上 CPU 号	
计算节点状态说明	
idle	节点空闲
busy	节点忙
boot	节点正在引导
sleeping	节点正在睡眠过程中
sleep	节点已睡眠
wakeup	节点正在从睡眠中唤醒
hardft	节点发生硬件故障
down	节点宕机
net_excp	节点已引导成功，但计算网络状态异常
softft	节点已引导成功，但全局文件系统不可用
全局文件系统状态说明	
OK	全局文件系统正常
unmounted	全局文件系统未挂载
计算网络状态说明	
OK	计算网络正常

down	停止
其他	非正常状态
使用示例	
1) cnload -c 1-8,14 查询 1 到 8, 以及 14 号 CPU 的状态	
2) cnload -o 1:0 查询 1 机舱 0 号中板上所有 CPU 的状态	

2.2.2 队列查询命令

命令格式	
qload < queue_name > [-l -w] [-mid -cab]	
qload < -pre prefix > [-l -w] [-mid -cab]	
功能说明	
指定队列查询节点状态	
参数说明	
queue_name	指定队列名，可用 all 指定所有用户队列
-pre prefix	指定需要查询的队列名前缀
-l	以长格式显示节点信息，包括作业号
-w	以表格形式显示各个队列的资源状态
-mid	以中板分类查询节点状态信息
-cab	以机舱分类查询节点状态信息
使用示例	
qload q_test 查询队列 q_test 上的所有 CPU 的状态	

2.2.3 队列状态查询

命令格式	
bqueues [-empty] [-w -l] [-u user -g group queue_name]	

功能说明	
显示队列状态，只有队列状态为 Open 时，用户才能够使用	
参数说明	
-w	长格式显示
-l	显示队列的详细信息
-u	查询指定用户可以使用的队列
-g	查询指定用户组可以使用的队列
-empty	显示未配置节点的队列
queue_name	显示指定队列对应的计算节点情况以及使用情况以及队列归哪些用户使用
注意事项	
如果不指定 queues-name，则显示符合条件的所有队列的状态	

2.3 开工管理

2.3.1 指定 CPU 开工

命令格式	
breset -cpu cpulist [-non2]	
功能说明	
实现对 cpu 的开工复位，操作系统核心和 IMAG 网络加载和引导；支持多个用户的单个多个 cpu 的并发开工模式	
参数说明	
-cpu	指定 CPU 列表
-non2	只对 CPU 进行复位，不复位对应的网卡
注意事项	

1) 开工是异步的过程，成功只表示开工流程正确，不代表 CPU 一定能够启动成功； 2) 开工时，默认以成对方式，连同 CPU 连接的网卡同时初始化。如 breset -cpu 0 将默认对 0 和 1 两个 CPU 同时开工，如需单独开工，请使用-non2 参数，如 breset -cpu 0 -non2； 3) 失败时，可以再次开工，如果多次开工失败，需要根据错误情况检查对应的软硬件环境。	
使用示例	
对 CPU0 进行开工操作	breset -cpu 0 -non2

2.3.2 队列开工

命令格式	
qboot queue_name [-non2]	
功能说明	
指定队列进行整队列 CPU 的开工操作	
参数说明	
queue_name	指定队列名称
-non2	只对队列内 CPU 进行复位，不复位对应的网卡
注意事项	
无。	
使用示例	
对队列 q_test 进行开工操作	qboot q_test -non2

2.4 作业管理

2.4.1 作业提交

作业提交成功后，将显示一行包含 jobid 的提示信息，其中包括作业 id 号，如” Job <102> is submitted to queue <queue>”，此时，jobid 就是 102，它是全局唯一的。一旦作业提交成功，用户对作业的各种操作就可以通过这个 jobid 来实现的。

命令格式

bsub [OPTIONS] command [CMD_OPTIONS]	
参数说明	
-h	显示帮助信息
-I	提交交互式作业，无该选项时为批式作业
-q	向指定的队列中提交作业，必选项
-p	在作业输出中打印作业分配的节点列表及位图
-exclu -shared	指定使用独占/共享模式
-n	指定需要的所有主核数
-N	指定需要的节点个数
-master	主任务模式
-np	指定每节点内使用的主核数
-mpecg	指定每个主核使用 CG 个数
-cgsp	指定每个 CG 内需要的从核个数，指定时该参数必须≤64。
-nodempemap	指定节点内的主核位图
-js	指定作业对应的课题代号
-node	指定运行作业的节点列表
-cross	要求分配全片 CPU（6 主核的 CPU）
-mpmd	提交 mpmd 模式的作业
-J	指定作业名
-job_type	指定作业课题类型
-health	指定分配资源的健康度级别
-perf	打开性能监测功能
-perff	使用指定配置文件进行作业性能统计
-perf_float	作业浮点性能统计

-o	将作业的 <code>stdout</code> 和 <code>stderr</code> 的输出定向到指定文件，可选项
-midnode	指定每个中板中分配的节点数
-cabnode	指定每个机舱中分配的节点数
-b	指定从核栈位于局存
-m value	提供从核自陷模式的控制，指定-m 2时，将浮点控制状态寄存器 <code>fcpr</code> 的最后两位设为01，允许除不精确结果之外的所有浮点算术异常自陷，相当于编译器使用-OPT:IEEE_arith=2选项；指定-m 1时，将 <code>fcpr</code> 最后两位设为00，允许所有浮点算术异常自陷，相当于编译器使用-OPT:IEEE_arith=1选项；其他所有值将不对默认的 <code>fcpr</code> 进行修改。
-share_size0	指定 0 号进程的核组共享空间大小
-priv_size0	指定 0 号进程的每个核上私有空间大小
-cross_size0	指定 0 号进程的交叉段大小
-ro_size0	指定0号进程的只读空间大小
-pe_stack0	指定0号进程的从核栈空间大小，默认为64K
-host_stack0	指定 0 号进程的主核栈空间大小，默认为 8M
-share_size	指定所有进程的核组共享空间大小
-priv_size	指定所有进程的每个核上私有空间大小
-cross_size	指定所有进程的交叉段大小
-ro_size	指定所有进程的只读空间大小
-pe_stack	指定所有进程的从核栈空间大小，默认为64K
-host_stack	指定所有进程的主核栈空间大小，默认为 8M
-ldm_share_mode	指定连续共享 LDM 模式（0、1、2、3、4、5） 0：单簇模式 1：双簇模式 2：四簇模式 4：全阵列簇模式 5：全阵列行模式
-ldm_share_size	指定连续共享 LDM 大小（0、4、8、16、32、64、128）KB

-swrun	指定使用特殊的加载器
-akernel	Akernel 模式，不使用加载器
-xmalloc	去加载器模式下使用_sw_xmalloc，返回交叉段地址
-crossmalloc	主核 malloc 返回交叉段地址
-flush_dcache	核心段执行完后刷新从核数据 cache
command	用户提交的可执行程序
CMD_OPTIONS	用户可执行程序的参数
使用示例	
向队列 queue 中提交交互式作业 myjob，该作业共使用 1 个节点，六个主核： bsub -I -q queue -N 1 -np 6 ./myjob	

2.4.2 作业查询

命令格式	
bjobs [-h] [-w] [-l] [-a -d -e -p -r] [-q queue_name] [-u user_name -u all] [jobId]	
参数说明	
-h	显示帮助
-w	以表格模式显示
-l	列举详细信息
-a	显示所有的作业（包括正在运行的、已经完成的、正在排队的作业），缺省为正在运行和正在排队的作业。
-d	显示正常完成的作业
-e	显示错误退出的作业
-p	显示正在排队等待调度运行的作业
-r	显示正在运行的作业
-q	指定队列

-u uname -u all	显示指定用户的作业，-u all 指定显示所有用户的作业，只有管理员才可以查询其他用户的作业
jobId	指定作业 ID
使用示例	
1) 查询系统中所有的作业 bjobs -u all 2) 查询系统中指定用户的作业 bjobs -u user-name 3) 查询系统中指定队列中的作业 bjobs -u user-name -q qname	

2.4.3 作业输出查询

命令格式	
bpeek [-h] [-f] jobId	
参数说明	
-h	显示帮助
-f	持续显示作业的输出信息，类似于 tail 的-f 选项
jobId	指定作业 ID
使用示例	
bpeek -f 12345	

2.4.4 作业联机

命令格式	
bonline [-h] jobId	
参数说明	
-h	显示帮助
jobId	指定作业 ID
使用示例	
bonline 12345	

注意事项
1) 只能普通用户操作本用户的作业， 2) 操作的对象只能是本用户的正在运行状态的交互作业。否则都是无效的，会报错退出。如果作业处于联机状态，则作业输出不再发送至原实时输出终端，只发送到本输出终端 3) 对作业联机后，可以在当前联机的会话窗口看到作业的实时输出信息

2.4.5 作业废除

命令格式	
bkill [-J jobName] [-q queue] [-f] [jobid]	
参数说明	
-J	指定作业名称
-q	指定队列
-u uname	废除指定用户的作业
-f	强制废除作业，没有交互确认
jobId	指定作业 ID
使用示例	
bkill 123456	
注意事项	
1) 普通用户只能废除自己的作业，而管理员可以废除所有用户的作业。 2) 普通用户给定-u <自身用户名>则废除自己的所有作业。 3) 发出作业废除命令到作业真正被废除可能需要一定的时间间隔（2 分钟以内） 4) 对于交互批作业（当前提交窗口可以看见作业输出），执行 ctrl+c 也可以终止作业，效果相同。	